

EM Algorithm Implement

Step 1. 初始化參數 μ_k^t 、 Σ_k^t 、 π_k^t ，分別代表第 k 群在迭代 t 的 mean、covariance matrix 與 occurrence probability， $\theta^t = \{\pi_k^t, \mu_k^t, \Sigma_k^t, k=1,2,3\}$ 。

在初代 $t = 1$ ，令 μ_k^t 為資料群中任意點， $\Sigma_k^t = I_{2 \times 2}$ ， $\pi_k^t = \frac{1}{3}$

Step 2. 計算在已知群體分布下，新的參數 μ_k^{t+1} 、 Σ_k^{t+1} 、 π_k^{t+1}

Step 3. 迭代 Step2 直到參數不變或變化量之和小於 T （預設 0.001）

$$T > V = \sum_{k=1}^3 \text{norm}(\mu_k^t - \mu_k^{t-1}) + \text{norm}(\Sigma_k^t - \Sigma_k^{t-1}) + \text{norm}(\pi_k^t - \pi_k^{t-1})$$

或是迭代直到所有資料點機率變化量之和小於 T

$$T > V = \sum_{k=1}^3 \pi_k^t f_k(x_i | \mu_k^t, \Sigma_k^t) - \pi_k^{t-1} f_k(x_i | \mu_k^{t-1}, \Sigma_k^{t-1})$$

Step 4. 計算各點在各群分布的機率 $\text{Prob}(x_i \in c_k | x_i, \theta^t)$ 並顯示結果圖

Method

E-Step:

使用參數 θ^t 求每點 x_i 在 c_k 群分布的期望值

$$T_k^t(x_i, \theta^t) = \text{Prob}(x_i \in c_k | x_i, \theta^t) = \frac{\pi_k^t f_k(x_i | \mu_k^t, \Sigma_k^t)}{\sum_{k=1}^3 \pi_k^t f_k(x_i | \mu_k^t, \Sigma_k^t)}, \theta^t = \{\pi_k^t, \mu_k^t, \Sigma_k^t, k=1,2,3\}$$

$f_k(x_i | \mu_k^t, \Sigma_k^t)$ 為 2-Dimension normal distribution probability density function

M-Step:

求新的分布參數

$$\pi_k^{t+1} = \frac{\sum_{i=1}^n T_k^t(x_i, \theta^t)}{\sum_{k=1}^3 \left(\sum_{i=1}^n T_k^t(x_i, \theta^t) \right)} = \frac{\sum_{i=1}^n T_k^t(x_i, \theta^t)}{n}$$

$$\mu_k^{t+1} = \sum_{i=1}^n x_i \left[\frac{T_k^t(x_i, \theta^t)}{\sum_{i=1}^n T_k^t(x_i, \theta^t)} \right], k=1, 2, 3$$

$$\Sigma_k^{t+1} = \sum_{i=1}^n \{ [(x_i - \mu_k^{t+1})(x_i - \mu_k^{t+1})^T] \left[\frac{T_k^t(x_i, \theta^t)}{\sum_{i=1}^n T_k^t(x_i, \theta^t)} \right] \}, k=1, 2, 3$$

Program

主程式 `hw6.m`，每次迭代會秀出目前分群結果的 `figure`，並在 `CMD` 顯示收斂情形，收斂後會秀出過程影片。

收斂結果方程式如下

$$V = \sum_{k=1}^3 \text{norm}(\mu_k^t - \mu_k^{t-1}) + \text{norm}(\Sigma_k^t - \Sigma_k^{t-1}) + \text{norm}(\pi_k^t - \pi_k^{t-1})$$

收斂情形分別顯示

$$\text{norm}(\pi_k^t - \pi_k^{t-1}) \quad \text{norm}(\mu_k^t - \mu_k^{t-1}) \quad \text{norm}(\Sigma_k^t - \Sigma_k^{t-1}) \quad V$$

當 V 小於 0.001 則停止迭代運算並秀圖

主程式	<code>hw6.m</code>
計算 $T'_k(x_i, \theta^t)$	<code>Estep.m</code>
計算 π_k^{t+1}	<code>MstepWeight.m</code>
計算 μ_k^{t+1}	<code>MstepMean.m</code>
計算 Σ_k^{t+1}	<code>MstepSigma.m</code>

影片

變數 `a` 儲存過程圖像，可使用 `movie(a)` 播放


或是 `movie2avi(a, 'result.avi', 'compression', 'None')` 儲存為 `avi` 檔案

Result


RGB Intensity 分別代表三群的 Probability $T'_k(x_i, \theta^t)$ ，黑點為各群中心 μ_k^t

avi 影片與結果 mat 資料放在 result 目錄下

Data1




開始 -----> 收斂




result1.avi & result1.mat

Data2



開始 -----> 收斂



result2.avi & result2.mat

Discussion

Initial μ_k^1 會影響到收斂速度，若隨機取三點 μ_k^1 ，很有可能都在非常接近的地方，會使得群體的 μ_k^t 移動緩慢，甚至在某些情況下會掉入意外的 **Local optimum**。若要加速收斂以及增加正確性，起始三點 μ_k^1 要盡量接近真實的群體中心並且散開。

為解決掉入 **Local optimum** 的問題，我們可以平行計算複數組 μ_k^1 並回傳最佳的分群結果。

平行運算 M 組 μ_k^1 ，分群收斂後，加總各點與最可能 **cluster mean** 的 **Euclidean distance** D_M ，取 D_M 最小的為最正確分群結果。

$$D_M = \sum_{i=1}^n \text{norm}(\mu_{\max \text{Prob}(x_i)} - x_i)$$